



Inteligência Artificial para Geração de Conteúdo Procedural Adaptativo

Um Estudo com GANs/VAE em Videojogos

Carlos Filipe Borges Moutinho

Aluno nº: 1140858

**Dissertação para obtenção do Grau de
Mestre em Engenharia de Inteligência Artificial**

Orientador: Maria Goreti Carvalho Marreiros

Júri:

Presidente:

[Nome do Presidente, Categoria, Escola]

Vogais:

[Nome do Vogal1, Categoria, Escola]

[Nome do Vogal2, Categoria, Escola] (até 4 vogais)

Porto, [Mês] [Ano] Calibri, 12pt

Página em branco [apagar este comentário]

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim. As exceções [REMOVER ESTE PERÍODO NO CASO DE NÃO SE APLICAR – APAGAR ESTE COMENTÁRIO] estão explicitamente reconhecidas na secção onde são abordadas as considerações éticas. Esta secção também declara como as ferramentas de Inteligência Artificial foram utilizadas e para que finalidade.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, [Dia] de [Mês] de [Ano]

[Optar pela versão em Português ou Inglês de acordo com a língua de redação do documento - apagar este comentário]

Página em branco [apagar este comentário]

Statement of Integrity

I hereby declare that I have conducted this academic work with integrity.

I have not plagiarised or applied any form of undue use of information or falsification of results along the process leading to its elaboration.

Therefore, the work presented in this document is original and was authored by me, having not been previously used for any other purpose. The exceptions [REMOVE THIS CLAUSE IF IT DOES NOT APPLY – REMOVE THIS COMMENT] are explicitly acknowledged in the section that addresses ethical considerations. This section also states how Artificial Intelligence tools were used and for what purpose.

I further declare that I have fully acknowledged the Code of Ethical Conduct of P.PORTO.

ISEP, Porto, [Month] [Day], [Year]

Página em branco [apagar este comentário]

Dedicatória (opcional)

....

Página em branco [apagar este comentário]

Resumo

Este documento contém as principais regras de formatação a aplicar na escrita do relatório da unidade curricular Projeto / Dissertação / Estágio, do Mestrado em Engenharia de Inteligência Artificial (MEIA), do Departamento de Engenharia Informática (DEI), do Instituto Superior de Engenharia do Porto (ISEP). As regras aqui apresentadas formam um conjunto de boas práticas recomendadas para a elaboração de uma dissertação. No entanto, recomenda-se a discussão destes e outros aspetos com o respetivo orientador.

São apresentadas as normas a seguir relativamente ao formato a usar, modo de organização do documento, regras gerais de formatação do texto, formatação de tabelas e figuras, inserção de referências bibliográficas no texto e apresentação das referências bibliográficas.

Este documento foi originalmente preparado pela Doutora Fátima Rodrigues (DEI/ISEP), tendo sido adaptado para o MEIA.

Palavras-chave: Palavra-chave1, ..., Palavra-chave6

Página em branco [apagar este comentário]

Abstract

O documento tese deve conter um resumo em português e outro em inglês que não excedam as 200 palavras ou 1 página A4. Quando o documento é escrito em português o abstract deve ser uma tradução em inglês do resumo.

Após o resumo/abstract é obrigatório colocar as principais palavras-chave/keywords do tema em que se insere o trabalho desenvolvido, sendo permitido um máximo de 6 palavras-chave/keywords, estas devem ser caraterizadoras do trabalho desenvolvido e surgirem com frequência no documento escrito.

Keywords: Keyword1, ..., Keyword6

Página em branco [apagar este comentário]

Agradecimentos <opcional>

Dirigidos ao(s) orientador(es), à família, aos colegas, às Instituições, ...

Página em branco [apagar este comentário]

Índice

1	Introdução	1
1.1	Contextualização	1
1.2	Contextualização da indústria dos videojogos	3
1.3	Descrição do problema	5
1.4	Questões e objetivos da investigação	6
1.5	Contribuições da dissertação	7
1.6	Estrutura do documento.....	7
1.7	Extra	Erro! Marcador não definido.
2	State of the Art and Systematic Review of the Literature	10
2.1	Introduction.....	10
2.2	Related literature	Erro! Marcador não definido.
2.2.1	Methodology of review	Erro! Marcador não definido.
2.2.2	Research Questions	Erro! Marcador não definido.
2.2.3	Definition of search strategy	Erro! Marcador não definido.
2.2.4	Definition of search sources	14
2.2.5	Definition of search terms	15
2.2.6	Study selection, inclusion and exclusion criteria	16
2.3	Results found	18
2.3.1	Study selection and characteristics.....	18
2.3.2	Subject coverage of studies	18
2.3.3	RQ1 – Modelos generativos e representações de níveis 2D	18
2.3.4	RQ2 – Mecanismos de adaptação ao jogador e métricas usadas	20
2.3.5	RQ3 – Métodos de validação algorítmica da jogabilidade.....	22
2.3.6	RQ4 – Telemetria do jogador, privacidade e conformidade legal	23
2.4	Discussion	24
2.4.1	RQ1 – Modelos generativos e representações de níveis 2D	24
2.4.2	RQ2 –	26
2.4.3	RQ3 –	27
2.4.4	RQ4 –	28
2.5	Conclusions and future work	28
3	State of the Art and Systematic Review of the Literature	30
3.1	Introduction.....	30

**Inserir página em branco apenas se necessário de modo
que a próxima secção comece numa página à direita**

Lista de Figuras

- Figura 1 – Esta legenda tem só uma linha **Erro! Marcador não definido.**
- Figura 2 – Esta legenda tem mais do que uma linha, por isso é justificada à esquerda, fonte calibri 10 pt., figura retirada de (Ramos 2008) **Erro! Marcador não definido.**
- Figura 3 – Relacionamento entre nº de argumentos e nº de simulações (Marreiros 2010) . **Erro! Marcador não definido.**
- Figura 4 – Visualização gráfica do resultado (Faria 2009)..... **Erro! Marcador não definido.**

**Inserir página em branco apenas se necessário de modo
a que a próxima secção comece numa página à direita**

Lista de Tabelas

Tabela 1 Questões de investigação consideradas na revisão da literatura	12
Tabela 2 Temas e termos de pesquisa utilizados na revisão sistemática	15
Tabela 3 Lista de critérios de inclusão	17
Tabela 4 Lista de critérios de exclusão.....	17

**Inserir página em branco apenas se necessário de modo
a que a próxima secção comece numa página à direita**

Acrónimos e Símbolos

Lista de Acrónimos

AA	Aprendizagem Automática
AS	Análise de Sentimentos
CNN	<i>Convolutional Neural Network</i> (texto que não está em português em itálico, se a tese estiver escrita em português)
IA	Inteligência Artificial
LSTM	<i>Long-Short Term Memory</i>
SVM	<i>Support Vector Machine</i>

Lista de Símbolos

η	Taxa de Aprendizagem
θ	<i>Threshold</i>

**Inserir página em branco apenas se necessário de modo
a que a próxima secção comece numa página à direita**

1 Introdução

Introduction

O seguinte capítulo enquadra o tema da dissertação e clarifica o problema de investigação que motiva o trabalho desenvolvido. A Secção 1.2 apresenta uma contextualização geral da indústria dos videojogos, enquanto a Secção 1.3 se foca no papel dos videojogos 2D, nas práticas de criação de níveis e na evolução das técnicas de Geração Procedural de Conteúdo baseadas em Aprendizagem Automática. A Secção 1.4 descreve o problema de investigação, identificando os principais desafios técnicos, adaptativos e éticos associados à geração automática de níveis 2D. Na Secção 1.5 são formulados as questões de investigação e os objetivos que orientam o desenvolvimento da dissertação. Por fim, as Secções 1.6 e 1.7 apresentam, respetivamente, as principais contribuições do trabalho e a estrutura global do documento.

1.1 Contextualização

Contextualisation

A indústria dos videojogos tem apresentado, ao longo das últimas décadas, um crescimento económico e cultural particularmente expressivo, acompanhando as tendências globais de expansão do mercado digital e de consolidação do entretenimento interativo como um dos setores mais relevantes da atualidade. De acordo com dados da Administração do Comércio Internacional do Departamento do Comércio dos Estados Unidos (International Trade Administration, 2023), a indústria global dos videojogos atingiu, em 2023, um valor aproximado de 184 mil milhões de dólares, contando com mais de 3,2 mil milhões de jogadores em todo o mundo, o que evidencia a escala, a maturidade e o impacto social deste ecossistema a nível global. No contexto norte-americano, o setor revelou igualmente uma relevância económica significativa, tendo criado e suportado mais de 350 mil postos de trabalho e contribuído com cerca de 66 mil milhões de dólares para o Produto Interno Bruto (PIB) dos Estados Unidos. Adicionalmente, estima-se que mais de 190 milhões de americanos joguem videojogos

regularmente, sendo que 78% dos agregados familiares utilizaram pelo menos um dispositivo de jogo nos doze meses anteriores, demonstrando a forte penetração deste meio na sociedade contemporânea.

Esta evolução tem sido acompanhada por uma intensificação das expectativas dos jogadores, que procuram experiências cada vez mais prolongadas, envolventes e personalizadas, indo além do entretenimento pontual e valorizando conteúdos capazes de se adaptar às suas preferências, ao seu estilo de jogo e ao seu nível de habilidade. Neste contexto, a confluência entre o crescimento sustentado da indústria e os avanços recentes na Inteligência Artificial (IA), em particular nas técnicas de aprendizagem profunda, tem permitido a emergência de novos paradigmas de criação de conteúdo, com destaque para a Procedural Content Generation (PCG) e, mais recentemente, para as abordagens de Procedural Content Generation Machine Learning (PCGML). Estas abordagens exploram a capacidade dos modelos de IA para aprender automaticamente padrões estilísticos e estruturais a partir de exemplos reais, possibilitando a criação de conteúdo variado, coerente e escalável (Summerville et al., 2018).

Simultaneamente, o interesse crescente em IA adaptativa e modelação de jogador tem enfatizado a necessidade de ajustar a experiência de jogo ao comportamento do utilizador, recorrendo a métricas simples, como o tempo de conclusão de um nível, o número de mortes ou a percentagem de exploração alcançada, para inferir o grau de desafio mais adequado. Esta preocupação não é exclusiva de sistemas adaptativos baseados em IA, estando também presente em géneros de jogos cuja experiência é, por natureza, dinâmica e não totalmente determinística. Exemplos incluem jogos de exploração de masmorras, jogos roguelike ou roguelite, nos quais a experiência de jogo não é idêntica entre partidas, apresentando variação significativa de uma sessão para outra. Neste contexto, existem jogos amplamente reconhecidos por utilizarem geração algorítmica de mundos ou cenários que exploram a ideia de experiências não repetitivas, valorizadas pelos jogadores por aumentarem a rejogabilidade e o envolvimento a longo prazo.

Neste enquadramento, observa-se que grandes empresas da indústria dos videojogos, nomeadamente a Sony e a Electronic Arts, têm explorado abordagens de adaptação dinâmica da experiência de jogo, através de patentes, suportadas por mecanismos de análise de desempenho e de telemetria do jogador, como métricas de progressão, tempo de jogo, número de falhas, padrões de sucesso ou retenção, complementadas, em alguns casos, por dados fisiológicos, tais como resposta galvânica da pele, frequência cardíaca ou indicadores de tensão muscular, recolhidos através de dispositivos ou comandos de jogo, conforme documentado em patentes que descrevem sistemas de ajuste automático da dificuldade e de outros parâmetros de jogo com base nesses sinais comportamentais e biométricos (Electronic Arts Inc., 2020; Sony Computer Entertainment Inc., 2011).

Neste panorama, torna-se evidente que a combinação entre IA generativa, PCG e adaptação ao jogador representa uma área emergente com aplicabilidade concreta no desenvolvimento de videojogos, exigindo investigação sistemática sobre modelos, representações, métodos de validação e implicações éticas associadas.

Para além do crescimento do mercado e da expansão do número de jogadores, a indústria enfrenta uma pressão crescente associada ao aumento da complexidade e dos custos de produção, particularmente em projetos de grande escala. Indicadores recentes sugerem uma tendência de subida dos orçamentos de desenvolvimento, com estimativas a apontarem para uma passagem de intervalos típicos de 50–150 milhões de dólares para valores na ordem dos 200 milhões de dólares ou mais em projetos atuais, podendo ter envolvido neles mais de 1.000 profissionais distribuídos por vários estúdios, para criar apenas um videojogo, refletindo assim o aumento de exigência técnica e de conteúdo esperado pelos jogadores (European Commission, 2023).

Esta dinâmica reforça a necessidade de metodologias que promovam maior eficiência e escalabilidade na criação de conteúdo, sobretudo em equipas pequenas e estúdios independentes, onde o esforço manual associado à produção e iteração de níveis constitui frequentemente um constrangimento significativo (European Commission, 2023). Esta pressão sobre os custos de desenvolvimento reflete-se igualmente no ecossistema de consumo, no qual se observam sinais de que o preço do hardware de jogo nem sempre segue o padrão histórico de redução progressiva ao longo do tempo, tendo sido anunciadas, nos últimos anos, atualizações de preço recomendadas para consolas em mercados específicos (Sony Interactive Entertainment, 2022, 2025).

Embora estes fatores dependam de variáveis económicas e estratégicas que vão para além do âmbito desta dissertação, contribuem para contextualizar a relevância de soluções técnicas orientadas para a redução do custo e do tempo de desenvolvimento, favorecendo abordagens mais eficientes e sustentáveis na produção de conteúdo para videojogos, particularmente em contextos onde a experiência de jogo é dinâmica e assenta na geração de conteúdos variados, não repetitivos e adaptáveis ao jogador.

1.2 Contextualização da indústria dos videojogos

Contextualisation of the video game industry

Atualmente observa-se uma predominância comercial dos títulos tridimensionais; contudo, os videojogos bidimensionais continuam a desempenhar um papel relevante no panorama contemporâneo, tanto pela sua acessibilidade técnica como pela expressividade do formato. Títulos 2D têm sido consistentemente reconhecidos em eventos internacionais de referência da indústria, como os The Game Awards e os BAFTA Games Awards (British Academy of Film & Arts, 2025; The Game Awards, 2018), evidenciando que o design bidimensional mantém uma presença crítica e cultural significativa. Esta relevância assenta igualmente numa tradição consolidada de géneros como os jogos de plataformas e de ação lateral, amplamente explorados por estúdios independentes e por equipas de menor dimensão.

Nos videojogos 2D, a experiência é frequentemente estruturada como uma sequência de níveis concebidos através de processos de level design, constituídos por plataformas, inimigos,

obstáculos, recompensas e zonas secretas. A construção manual destes níveis é um processo intensivo, que exige competências especializadas e múltiplas iterações de afinação. Para equipas pequenas, este esforço pode constituir um entrave significativo, sobretudo quando se pretende oferecer grandes quantidades de conteúdo, variantes alternativas ou níveis adaptados a diferentes perfis de jogador.

As abordagens clássicas de Geração Procedural de Conteúdo baseadas em regras definidas por especialistas, gramáticas, algoritmos evolutivos e métodos de procura heurística têm fornecido soluções relevantes para a automatização da criação de conteúdo. Contudo, estas abordagens dependem de uma definição manual minuciosa de regras e de funções de avaliação e nem sempre conseguem capturar adequadamente os padrões característicos do design concebido por designers humanos. Estas limitações motivaram a investigação em Geração Procedural de Conteúdo via Aprendizagem Automática, na qual a geração é orientada por modelos treinados diretamente sobre exemplos reais, permitindo aprender distribuições complexas e produzir instâncias plausíveis do espaço de design (Summerville et al., 2018).

No âmbito da Geração Procedural de Conteúdo via Aprendizagem Automática, a investigação tem-se centrado progressivamente em modelos generativos profundos, capazes de aprender diretamente a partir de exemplos reais de conteúdo (Summerville et al., 2018). Entre estas abordagens, destacam-se os Variational Auto-Encoders (VAE) e as Generative Adversarial Networks (GANs) (Liu et al., 2021). Os VAE são modelos generativos baseados numa arquitetura encoder-decoder, cujo objetivo consiste em aprender uma representação latente contínua dos dados, conciliando a reconstrução dos exemplos de treino com a regularização do espaço latente. Por sua vez, as GAN assentam num processo adversarial entre um gerador e um discriminador, no qual o gerador aprende a produzir amostras que imitam a distribuição dos dados reais (Liu et al., 2021).

No contexto dos videojogos, estes modelos têm sido aplicados à geração de níveis através da representação matricial ou imagética do conteúdo, suportada por arquiteturas convolucionais. (Liu et al., 2021). Para além das suas aplicações em geração de conteúdo, as CNN são amplamente utilizadas em tarefas de processamento e melhoria de imagem, como classificação, segmentação e super-resolução, aproveitando a sua capacidade de extrair características espaciais em dados com topologia de grelha, como imagens. Esta versatilidade reforça a sua adequação ao domínio dos videojogos 2D, onde a representação matricial de níveis beneficia da estrutura espacial capturada por estas redes (Sony Interactive Entertainment, 2024).

A capacidade destes modelos para aprender distribuições complexas permite capturar padrões espaciais característicos do design de níveis, tornando possível gerar novo conteúdo com coerência estrutural e estilo semelhante aos dados reais. Neste enquadramento, a indústria evidencia simultaneamente uma necessidade prática de aumentar a eficiência e a variedade do conteúdo produzido e um interesse científico em explorar mecanismos de adaptação automática baseados no comportamento do jogador, situando-se assim na interseção entre PCG, IA generativa e IA adaptativa.

1.3 Descrição do problema

Description of the problem

A presente dissertação centra-se num conjunto de desafios que decorrem da intersecção entre as exigências da produção de níveis em videojogos 2D, as expectativas cada vez maiores dos jogadores e as limitações das abordagens atuais de geração automática de conteúdo. Em muitos videojogos 2D, o nível constitui a unidade fundamental da experiência, determinando o ritmo, a dificuldade, o espaço de exploração e a estrutura do desafio. A criação manual destes níveis é, contudo, um processo exigente, altamente especializado e difícil de escalar. Produzir grandes quantidades de conteúdo coerente implica um investimento substancial de tempo e recursos, especialmente para equipas pequenas ou estúdios independentes, que frequentemente não dispõem da capacidade necessária para manter várias iterações de design com o mesmo grau de detalhe e consistência.

Esta dificuldade é agravada pelo facto de os jogadores apresentarem perfis, ritmos de progressão e níveis de habilidade distintos, o que torna desejável que a experiência de jogo se adapte dinamicamente ao comportamento e ao desempenho de cada utilizador. Métricas simples, como o tempo necessário para completar um nível, o número de mortes ocorridas, a percentagem de exploração alcançada ou a quantidade de inimigos derrotados, permitem inferir se um determinado nível se encontra excessivamente fácil, demasiado difícil ou ajustado ao jogador.

A relevância deste desafio é ainda evidenciada pelo facto de a própria indústria ter explorado mecanismos de adaptação dinâmica da experiência de jogo, como ilustrado por patentes que descrevem o ajuste de dificuldade com base em sinais fisiológicos do jogador ou em métricas de telemetria e retenção (Electronic Arts Inc., 2020; Sony Computer Entertainment Inc., 2011). Estes esforços reforçam a pertinência do problema, mas não eliminam as dificuldades associadas à criação escalável e adaptativa de níveis em videojogos 2D.

Por outro lado, embora as abordagens clássicas de Geração Procedural de Conteúdo tenham permitido automatizar parcialmente o processo de criação de níveis, continuam dependentes de regras explícitas, gramáticas ou algoritmos evolutivos cuidadosamente construídos por especialistas. Estas abordagens exigem um esforço considerável na definição de heurísticas e funções de avaliação, e nem sempre conseguem capturar de forma natural as regularidades estilísticas presentes nos níveis criados manualmente (Summerville et al., 2018). Os avanços da aprendizagem profunda motivaram, assim, a transição para métodos de PCG via Aprendizagem Automática (PCGML), em que modelos treinados sobre exemplos reais aprendem distribuições complexas e se tornam capazes de gerar conteúdo plausível. Modelos generativos profundos, como Variational Auto-Encoders (VAE) e Generative Adversarial Networks (GANs) condicionais, têm mostrado particular potencial na geração de níveis representados matricialmente, permitindo reconstruir, extrapolar e adaptar padrões espaciais típicos do design de plataformas 2D (Liu et al., 2021).

Contudo, a utilização destes modelos levanta problemas adicionais que necessitam de ser tratados de forma sistemática. É essencial garantir que os níveis gerados mantêm propriedades mínimas de jogabilidade e progressão, o que requer mecanismos algorítmicos de validação. Uma abordagem comum consiste na transformação do nível num grafo, permitindo verificar a existência de um caminho viável entre pontos essenciais, tendo em conta as restrições do movimento do jogador e as estruturas presentes. Existe também a necessidade de controlar a geração de conteúdo para que este responda a métricas de desempenho, introduzindo uma componente de adaptação dinâmica que aproxime o sistema de níveis personalizados (Liu et al., 2021).

Para além dos desafios técnicos associados à geração e adaptação de níveis, a utilização de telemetria introduz preocupações éticas e legais relacionadas com a privacidade dos dados dos jogadores. Mesmo quando se utilizam métricas mínimas e não intrusivas, é essencial justificar a sua recolha, limitar o seu armazenamento e garantir a conformidade com os princípios do Regulamento Geral sobre a Proteção de Dados (RGPD).

Apesar dos avanços registados na literatura, permanece em aberto a questão de como integrar modelos generativos profundos com mecanismos simples e controláveis de adaptação ao jogador, garantindo simultaneamente a jogabilidade dos níveis gerados, a coerência estrutural do conteúdo e o respeito por constrangimentos éticos e legais associados à recolha de telemetria.

Deste modo, o problema que esta dissertação procura abordar consiste em desenvolver um sistema capaz de gerar automaticamente níveis 2D variados, coerentes e adaptativos, utilizando modelos generativos treinados sobre exemplos reais, assegurando simultaneamente a jogabilidade, o controlo adaptativo e o respeito pelo enquadramento ético e legal.

1.4 Questões e objetivos da investigação

Research questions and objectives

A presente dissertação é orientada por uma questão de investigação central que resulta dos desafios identificados no contexto da geração procedural de níveis em videojogos 2D, nomeadamente a necessidade de conjugar geração automática de conteúdo, garantia de jogabilidade e adaptação ao desempenho do jogador. Neste enquadramento, a questão de investigação principal que orienta o trabalho é a seguinte: “De que forma a integração de modelos generativos profundos (GANs/VAE) com mecanismos de validação baseados em grafos permite a criação de níveis 2D que sejam simultaneamente jogáveis e adaptáveis ao desempenho do utilizador?”

Para responder a esta questão, a dissertação estabelece um conjunto de objetivos de investigação, de natureza técnica e experimental, que orientam o desenvolvimento do trabalho e a avaliação das soluções propostas. Em particular, pretende-se:

- Desenvolver um sistema de geração procedural de níveis 2D baseado em modelos generativos profundos, utilizando VAE e GAN condicionais treinados sobre níveis representados de forma matricial ou imagética;
- Definir e implementar mecanismos de validação algorítmica de jogabilidade baseados em grafos, capazes de assegurar propriedades mínimas de progressão e acessibilidade nos níveis gerados;
- Integrar métricas simples de desempenho do jogador no processo de geração, de forma a permitir a adaptação controlada dos níveis a diferentes perfis de utilizador;
- Avaliar experimentalmente a qualidade dos níveis gerados, considerando critérios de jogabilidade, coerência estrutural e capacidade de adaptação;
- Analisar as implicações éticas e legais associadas à recolha e utilização de telemetria do jogador, garantindo conformidade com princípios de minimização de dados e com o Regulamento Geral sobre a Proteção de Dados (RGPD).

Estes objetivos orientam o desenvolvimento metodológico e experimental da dissertação, servindo de base à definição das opções técnicas adotadas e à análise crítica dos resultados apresentados nos capítulos seguintes.

1.5 Contribuições da dissertação

Contributions of the dissertation

O documento pode ser escrito em português ou em inglês. O limite de páginas mínimo é de 60 páginas e máximo de 120 páginas, formato A4, Fonte Calibri de dimensão 11 pt, a espaço e meio. Em Word poderá utilizar o estilo Text, já definido no separador Home grupo Quick Styles. Note-se que todos estilos principais estão disponíveis no mesmo local. As páginas deverão ter margens Top: 3.5 cm, Bottom: 2.5, Inside: 3.5, Outside: 2.6. Different odd and even pages. A tese deverá ser impressa em frente e verso.

1.6 Estrutura do documento

Document structure

O documento pode ser escrito em português ou em inglês. O limite de páginas mínimo é de 60 páginas e máximo de 120 páginas, formato A4, Fonte Calibri de dimensão 11 pt, a espaço e meio. Em Word poderá utilizar o estilo Text, já definido no separador Home grupo Quick Styles. Note-se que todos estilos principais estão disponíveis no mesmo local. As páginas deverão ter

margens Top: 3.5 cm, Bottom: 2.5, Inside: 3.5, Outside: 2.6. Different odd and even pages. A tese deverá ser impressa em frente e verso.

Inserir página em branco apenas se necessário de modo a que o próximo capítulo comece numa página à direita

2 Estado da arte e revisão sistemática da literatura

State of the Art and Systematic Review of the Literature

2.1 Introdução

Introduction

O presente capítulo apresenta o estado da arte e a revisão sistemática da literatura que suportam a dissertação, seguindo as diretrizes PRISMA, com o objetivo de identificar, organizar e sintetizar as abordagens existentes sobre geração procedural de níveis em videojogos 2D com recurso a técnicas de inteligência artificial, bem como os mecanismos de adaptação ao jogador, validação algorítmica da jogabilidade e implicações associadas à recolha de telemetria. A Secção 2.2 descreve a metodologia da revisão, definindo as questões de investigação, a estratégia de pesquisa, as fontes e termos utilizados, e os critérios de inclusão e exclusão aplicados. A Secção 2.3 apresenta e caracteriza os estudos selecionados, sintetizando os resultados obtidos por questão de investigação. Na Secção 2.4 é realizada uma discussão crítica dos achados, destacando tendências, limitações e lacunas relevantes na literatura. Por fim, a Secção 2.5 resume as principais conclusões da revisão e aponta direções de trabalho futuro, enquadrando-as com os objetivos do protótipo e do contributo experimental da dissertação.

2.2 Literatura relacionada

Related literature

2.2.1 Metodologia da revisão

Methodology of review

A presente dissertação apresenta uma revisão sistemática da literatura conduzida de acordo com as diretrizes Preferred Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA), com o objetivo de analisar e sistematizar o estado da arte relativo à aplicação de modelos generativos baseados em inteligência artificial na Geração Procedural de Conteúdo em videojogos 2D, com particular enfoque na adaptação ao perfil do jogador, na validação algorítmica de jogabilidade e nas implicações éticas associadas à recolha de telemetria.

A metodologia adotada visa garantir transparência, reprodutibilidade e rigor científico ao processo de revisão, permitindo identificar tendências, lacunas e desafios existentes na literatura. Para esse efeito, o processo de revisão foi estruturado em várias fases, incluindo a definição das questões de investigação, a seleção das fontes de pesquisa, a definição das estratégias e termos de pesquisa, a aplicação de critérios de inclusão e exclusão, a seleção dos estudos relevantes e, por fim, a extração, análise e síntese dos resultados.

A pesquisa bibliográfica incidiu sobre estudos publicados em revistas científicas e atas de conferências com revisão por pares, no período temporal definido, focando trabalhos relacionados com a aplicação de técnicas de inteligência artificial à geração de conteúdo em videojogos, sem a assunção prévia de modelos ou abordagens específicas, de modo a permitir que as soluções mais relevantes emergjam da literatura analisada. Foram igualmente considerados estudos que abordem mecanismos de adaptação da experiência de jogo ao comportamento do jogador, métodos de validação de jogabilidade e aspetos relacionados com privacidade e proteção de dados.

O processo de seleção dos estudos seguiu uma abordagem faseada. Numa primeira etapa, procedeu-se à identificação dos registos provenientes das bases de dados selecionadas, sendo posteriormente efetuada a remoção de duplicados com base no identificador DOI e na normalização dos títulos. Após a remoção de duplicados, os estudos restantes foram sujeitos a uma fase de triagem inicial, baseada na análise dos títulos e resumos, com o objetivo de excluir trabalhos irrelevantes para o âmbito da investigação. Numa fase subsequente, os textos completos dos estudos potencialmente relevantes foram analisados em detalhe, de forma a verificar o cumprimento dos critérios de inclusão e exclusão previamente definidos.

Os resultados da revisão são apresentados de forma estruturada por questão de investigação, sendo complementados, sempre que pertinente, por tabelas e esquemas de síntese. O processo global de identificação, seleção, elegibilidade e inclusão dos estudos é resumido através de um diagrama PRISMA, assegurando a rastreabilidade e clareza metodológica da revisão realizada.

2.2.2 Questões de investigação

Research Questions

A presente revisão sistemática é orientada por uma questão de investigação central definida especificamente para o processo de revisão da literatura, a qual visa estruturar e delimitar a análise do estado da arte de acordo com as diretrizes PRISMA. Embora esta questão se encontre alinhada com o tema geral da dissertação, o seu âmbito é distinto do objetivo principal do trabalho experimental, incidindo exclusivamente sobre a identificação, caracterização e sistematização das abordagens existentes na literatura científica relativas à geração procedural de níveis em videojogos 2D, à adaptação ao jogador e à validação da jogabilidade. Esta distinção permite garantir clareza metodológica e evitar a sobreposição entre os objetivos da revisão sistemática e os objetivos da investigação desenvolvida na dissertação. A questão de investigação principal definida é a seguinte: “De que forma técnicas de inteligência artificial, em particular modelos generativos, têm sido aplicadas à geração de níveis em videojogos 2D na literatura recente, e que abordagens têm sido propostas para a validação da jogabilidade e adaptação ao jogador?”

Para apoiar a resposta a esta questão central, a literatura é analisada com base em quatro questões de investigação específicas, apresentadas na Tabela 1 Questões de investigação consideradas na revisão da literatura. Em conjunto, estas questões permitem organizar a análise dos estudos selecionados e identificar tendências, abordagens e lacunas relevantes no domínio em estudo.

Tabela 1 Questões de investigação consideradas na revisão da literatura

Identificador	Questão
RQ1	Que tipos de modelos generativos baseados em inteligência artificial têm sido utilizados na literatura para a geração procedural de níveis em videojogos 2D, e que representações matriciais ou imagéticas dos níveis são adotadas?
RQ2	Que mecanismos de adaptação ao jogador são descritos na literatura no contexto da geração procedural de níveis em videojogos 2D, e que métricas de desempenho ou comportamento são utilizadas para esse efeito?
RQ3	Que métodos de validação algorítmica da jogabilidade têm sido propostos para níveis gerados automaticamente em videojogos 2D?
RQ4	De que forma a recolha e utilização de dados de telemetria do jogador em sistemas de geração adaptativa de níveis, e que preocupações relacionadas com privacidade, minimização de dados e conformidade legal são discutidas?
RQ5 (Dados e reprodutibilidade talvez)	Que datasets/jogos (p.ex., Mario, Zelda, Sokoban), configurações e práticas de reprodutibilidade (código, seeds, splits, disponibilização) são usados? (Muito útil para mostrar lacunas e justificar o teu protótipo.)

RQ5 (Avaliação/validação experimental) talvez	Como é que os estudos avaliam a qualidade dos níveis gerados (métricas, testes com utilizadores, agentes, comparações com baselines) e que evidência reportam? (Isto complementa a tua RQ3, que está mais focada em validação algorítmica de jogabilidade; aqui apanhas também avaliação empírica/quantitativa.)
---	---

A RQ1 incide sobre os tipos de modelos generativos baseados em inteligência artificial descritos na literatura para a geração procedural de níveis em videojogos 2D, bem como sobre as representações matriciais ou imagéticas adotadas para codificar esses níveis. Esta questão permite identificar e comparar as diferentes abordagens existentes, analisando de que forma os níveis são representados para efeitos de aprendizagem automática e quais os modelos mais frequentemente utilizados neste contexto.

A RQ2 centra-se nos mecanismos de adaptação ao jogador descritos na literatura no âmbito da geração procedural de níveis em videojogos 2D. Em particular, esta questão analisa que métricas de desempenho ou comportamento do jogador, como tempo de conclusão, número de falhas ou padrões de exploração, são utilizadas para informar ou condicionar o processo de geração, permitindo compreender como a adaptação do conteúdo tem sido abordada nos estudos existentes.

A RQ3 aborda os métodos de validação algorítmica da jogabilidade propostos para níveis gerados automaticamente em videojogos 2D. O objetivo desta questão é identificar as estratégias utilizadas para assegurar propriedades mínimas de jogabilidade e progressão, tais como a existência de percursos viáveis ou a acessibilidade entre regiões do nível, garantindo que o conteúdo gerado é funcional do ponto de vista do jogador.

Por fim, a RQ4 analisa de que forma a literatura aborda a recolha e utilização de dados de telemetria do jogador em sistemas de geração adaptativa de níveis. Esta questão permite identificar as preocupações discutidas relativamente à privacidade, minimização e proteção de dados, bem como os enquadramentos legais considerados, nomeadamente no que respeita à conformidade com regulamentos de proteção de dados aplicáveis.

2.2.3 Definição de estratégia de pesquisa

Definition of search strategy

A estratégia de pesquisa foi definida com o objetivo de identificar estudos científicos relevantes para responder às questões de investigação formuladas nesta revisão sistemática. A pesquisa foi delineada de forma a abranger os principais tópicos associados à geração procedural de níveis em videojogos 2D recorrendo a técnicas de inteligência artificial, bem como os mecanismos de adaptação ao jogador, a validação algorítmica da jogabilidade e as implicações

associadas à recolha e utilização de dados de telemetria, tal como discutidos na literatura científica.

Atendendo à diversidade temática das questões de investigação, a estratégia de pesquisa foi estruturada através de um conjunto de expressões de pesquisa organizadas em torno de uma query base (Q0) e de queries complementares por eixo temático (Q1–Q4), aplicadas de forma independente. A query base foi concebida para identificar estudos relacionados com a aplicação de técnicas de inteligência artificial à geração procedural de níveis em videojogos, assegurando uma cobertura abrangente do domínio. As queries complementares foram definidas para aprofundar aspetos específicos correspondentes às questões de investigação, nomeadamente a representação dos níveis (RQ1), os mecanismos de adaptação ao jogador (RQ2), os métodos de validação algorítmica da jogabilidade (RQ3) e a recolha e utilização de dados de telemetria, incluindo considerações relativas à privacidade e proteção de dados (RQ4).

Cada uma das expressões de pesquisa foi aplicada de forma consistente às bases de dados selecionadas, sendo os resultados obtidos posteriormente agregados no processo de revisão sistemática. Após a agregação, procedeu-se à remoção de duplicados com base no identificador DOI e na normalização dos títulos, antes das fases de triagem e avaliação de elegibilidade. Esta opção metodológica permitiu assegurar uma cobertura adequada da literatura relevante em cada um dos eixos de investigação, reduzindo o risco de exclusão de estudos pertinentes que abordam apenas subconjuntos específicos do problema em análise. As expressões de pesquisa foram definidas de modo a equilibrar abrangência e precisão, recorrendo a combinações de termos-chave e operadores lógicos que refletem os conceitos centrais das questões de investigação, sendo a definição detalhada das fontes e dos termos utilizados apresentada nas secções seguintes.

2.2.4 Definição de fontes de pesquisa

Definition of search sources

A pesquisa bibliográfica foi realizada em bases de dados científicas amplamente reconhecidas nas áreas da Engenharia Informática, Inteligência Artificial e Tecnologias de Videojogos, de forma a garantir a qualidade, relevância e diversidade dos estudos incluídos na revisão sistemática. Foram utilizadas as bases de dados IEEE Xplore, Web of Science, ACM Digital Library e Scopus, selecionadas por cobrirem revistas científicas e atas de conferências com revisão por pares relevantes para os domínios da inteligência artificial aplicada aos videojogos, da geração procedural de conteúdo, da adaptação ao jogador e da validação algorítmica da jogabilidade.

As expressões de pesquisa definidas na estratégia de pesquisa (Q0–Q4) foram aplicadas de forma consistente a todas as bases de dados selecionadas, permitindo uma recolha sistemática e comparável dos estudos disponíveis. A utilização conjunta destas fontes contribuiu para uma pesquisa abrangente e equilibrada, reduzindo o risco de viés associado à dependência de uma

única fonte e aumentando a probabilidade de identificação dos estudos mais relevantes para responder às questões de investigação definidas.

2.2.5 Definição dos termos de pesquisa

Definition of search terms

Os termos de pesquisa foram definidos com base nas questões de investigação apresentadas na Subsecção **Erro! A origem da referência não foi encontrada.**, com o objetivo de captar os conceitos centrais associados à geração procedural de níveis em videojogos 2D recorrendo a técnicas de inteligência artificial, à adaptação do conteúdo ao perfil do jogador, à validação algorítmica de jogabilidade e às implicações relacionadas com a recolha e utilização de dados de telemetria.

A definição dos termos de pesquisa procurou equilibrar abrangência e precisão, recorrendo a terminologia amplamente utilizada na literatura científica. Os termos foram organizados por eixos conceptuais correspondentes às questões de investigação, distinguindo entre uma query base, destinada a capturar estudos sobre geração procedural de níveis recorrendo a técnicas de inteligência artificial (Q0), e conjuntos de termos específicos utilizados em queries complementares por eixo temático (Q1–Q4). Para maximizar a recuperação de estudos relevantes, os termos foram aplicados aos campos título, resumo, palavras-chave do autor e termos de indexação, sempre que suportado pelas bases de dados utilizadas. Os termos foram organizados por temas, refletindo os diferentes eixos conceptuais associados às questões de investigação.

De acordo com a estratégia de pesquisa adotada, os termos definidos foram combinados utilizando operadores lógicos booleanos (AND, OR) para a construção das expressões de pesquisa finais. Sempre que relevante, foram consideradas variantes lexicais e diferentes formas de escrita dos termos, de modo a acomodar variações terminológicas entre áreas e bases de dados. As expressões de pesquisa foram ajustadas à sintaxe de cada base de dados, mantendo a base conceptual em todas as pesquisas realizadas.

Tabela 2 Temas e termos de pesquisa utilizados na revisão sistemática

Tema	Descrição	Termos de pesquisa exemplificativos
Geração Procedural de Conteúdo	Conceitos associados à geração automática de conteúdo em videojogos	procedural content generation, PCG, game level generation, level generation, content generation

Videojogos 2D	Domínio específico de aplicação dos sistemas de geração	2D games, platform game, side-scrolling game, tile-based level
Modelos baseados em IA	Técnicas de inteligência artificial utilizadas na geração de níveis	artificial intelligence, machine learning, deep learning, generative model, representation learning
Representação de níveis	Formas de codificação estrutural dos níveis para processamento computacional	matrix representation, image-based representation, grid-based levels, tile representation
Adaptação ao jogador	Mecanismos de ajuste do conteúdo com base no comportamento do jogador	player modeling, adaptive games, dynamic difficulty adjustment, player performance metrics
Validação de jogabilidade	Métodos para garantir propriedades mínimas de jogabilidade	playability validation, graph-based validation, pathfinding, reachability analysis
Telemetria e privacidade	Recolha e utilização de dados do jogador e implicações legais	player telemetry, game analytics, data privacy, data protection, GDPR

Os termos associados ao domínio dos videojogos 2D (por exemplo, 2D games, platform games, tile-based levels) foram utilizados como filtros incrementais em queries específicas, não sendo necessariamente incluídos como requisitos obrigatórios na query base, de forma a evitar a exclusão indevida de estudos relevantes que não explicitam estas características nos campos de pesquisa.

2.2.6 Seleção de estudos, critérios de inclusão e exclusão

Study selection, inclusion and exclusion criteria

A seleção dos estudos foi conduzida com base em critérios de inclusão e exclusão claramente definidos, com o objetivo de assegurar que os trabalhos considerados na revisão sistemática são relevantes para o âmbito da investigação, metodologicamente adequados e diretamente relacionados com as questões de investigação formuladas. A definição destes critérios permitiu orientar o processo de seleção de forma consistente, reduzindo o risco de viés e garantindo a comparabilidade dos estudos analisados.

Os critérios de inclusão foram definidos de modo a abranger estudos que contribuam para a compreensão da aplicação de técnicas de inteligência artificial à geração procedural de níveis em videojogos 2D, bem como para a análise de mecanismos de adaptação ao jogador, validação algorítmica de jogabilidade e utilização de telemetria. Desta forma, assegura-se que os estudos incluídos apresentam relevância científica e enquadramento direto com os objetivos da revisão

sistemática. Foram definidos os seguintes critérios de inclusão para a seleção dos estudos considerados na revisão:

Tabela 3 Lista de critérios de inclusão

Identificador	Questão
IC1	O estudo deve abordar a aplicação de técnicas de inteligência artificial à geração procedural de conteúdo em videojogos;
IC2	O estudo deve considerar a geração ou adaptação de níveis em videojogos 2D;
IC3	O estudo deve abordar pelo menos um dos seguintes aspetos, em alinhamento com as questões de investigação definidas: “(i) a geração procedural ou representação de níveis em videojogos 2D recorrendo a técnicas de inteligência artificial (RQ1)”, “(ii) mecanismos de adaptação ao jogador e métricas de desempenho ou comportamento (RQ2)”, “(iii) métodos de validação algorítmica da jogabilidade (RQ3)”, “(iv) recolha e utilização de dados de telemetria do jogador, incluindo considerações relativas à privacidade e proteção de dados (RQ4)”;
IC4	O estudo deve ter sido publicado em revistas científicas ou atas de conferências com revisão por pares.

Estes critérios de inclusão foram definidos de forma a garantir a coerência direta entre os estudos selecionados e as questões de investigação (RQ1–RQ4), permitindo a inclusão de trabalhos que abordem apenas subconjuntos específicos do problema em análise, sem prejuízo da cobertura global da revisão sistemática.

Os critérios de exclusão foram definidos com o intuito de eliminar estudos que, embora potencialmente relacionados com temas adjacentes, não contribuem de forma direta ou relevante para responder às questões de investigação, ou que não apresentam o nível de rigor científico necessário para integração na revisão sistemática. Foram definidos os seguintes critérios de exclusão para a seleção dos estudos considerados na revisão:

Tabela 4 Lista de critérios de exclusão

Identificador	Questão
EC1	Publicações não escritas em inglês ou português;
EC2	Publicações publicadas anteriormente a 2010, por se tratar de um período anterior à consolidação das técnicas modernas de inteligência artificial aplicadas à geração procedural de conteúdo;
EC3	Estudos que não se enquadram no domínio dos videojogos ou da Geração Procedural de Conteúdo;
EC4	Estudos que correspondem a artigos de opinião, resumos alargados, tutoriais, relatórios técnicos ou literatura cinzenta;

2.3 Resultados encontrados

Results found

2.3.1 Seleção e características do estudo

Study selection and characteristics

Iniciar um capítulo novo sempre numa página à direita (ímpar).

2.3.2 Seleção e características do estudo

Study selection and characteristics

Iniciar um capítulo novo sempre numa página à direita (ímpar).

2.3.3 RQ1 — Modelos generativos e representações de níveis 2D

A literatura converge em duas opções metodológicas centrais na geração procedural de níveis 2D: (i) a representação do nível, isto é, a forma como a estrutura espacial é codificada, e (ii) a escolha de modelos da família de modelos generativos, que aprende, a partir de amostras, a distribuição do conteúdo. Esta combinação condiciona diretamente o tipo de regularidades capturadas (locais vs. globais), a capacidade de generalização e o grau de controlo sobre o conteúdo gerado (Summerville et al., 2018).

De forma consistente, a literatura descreve a codificação de níveis 2D como um problema de representação estruturada: antes de treinar um modelo generativo, é necessário decidir como transformar um nível num formato manipulável por algoritmos de aprendizagem automática. As representações mais frequentes podem agrupar-se em sequências, grelhas/matrizes e grafos, que correspondem, respetivamente, a (i) dados ordenados adequados a modelos autorregressivos, (ii) dados espaciais em grelha adequados a modelos que exploram vizinhanças locais, e (iii) estruturas relacionais adequadas quando a conectividade entre regiões/entidades é mais relevante do que a geometria exata. Em jogos 2D baseados em tiles, a grelha é a codificação mais direta, mas representações sequenciais continuam a ser comuns quando o nível pode ser linearizado (por exemplo, em videojogos de plataformas com progressão predominantemente da esquerda para a direita), convertendo o mapa em fatias/colunas (slices)

ou numa cadeia de símbolos, o que permite aplicar modelos típicos de previsão de tokens e modelação de dependências ao longo do “percurso” do nível (Summerville et al., 2018).

Tabela 5 Taxonomia das técnicas por representação

Técnica / família	Sequência	Grelha/Matriz	Grafo
Modelos probabilísticos (Markov / n-grams / MdMC)	✓	✓	–
Redes recorrentes (LSTM/GRU) e variantes com atenção	✓	✓ (via linearização)	–
Transformers (self-attention)	✓ (tokens)	✓ (matriz→embeddings)	–
Modelos convolucionais/autoencoders/GAN (imagem)	–	✓ (imagem/matriz)	–
Representações relacionais (entidades/ligação/adjacência)	–	–	✓

Como podemos observar na Tabela 5, na geração de níveis, a forma de representar o nível (sequência, grelha ou grafo) é uma escolha separada da técnica usada para aprender/gerar conteúdo. Como estas escolhas são independentes, a mesma abordagem pode ser aplicada a representações diferentes, e técnicas semelhantes podem surgir descritas sobre formatos distintos de codificação (Summerville et al., 2018).

As abordagens baseadas em cadeias de Markov são recorrentes na literatura de PCG para níveis de videojogos 2D quando o objetivo é aprender regularidades estatísticas a partir de níveis existentes. Nestes casos, o nível é tipicamente descrito como uma coleção de estados discretos (tiles/sprites) e a geração resulta da amostragem de transições probabilísticas entre esses estados, aprendidas por contagem de frequências. Dependendo do estudo, a modelação pode ser feita após transformar o nível do videojogo 2D numa sequência (formato 1D), ou preservando a estrutura espacial através de vizinhanças (formato 2D), o que é particularmente natural em tilemaps (que é na prática uma grelha 2D, ou seja, uma matriz em que cada célula contém um tile (um identificador de bloco/terreno/objeto) (Zafar et al., 2019). No contexto de geração mais “generalista”, existem trabalhos que assumem explicitamente o nível como matriz 2D de sprites (em enquadramentos como Video Game Description Language (VGDL), que é uma linguagem/formalismo para descrever jogos (regras, entidades e níveis) de forma estruturada ou General Video Game Level Generation (GVG-LG), descrevendo a própria cadeia de Markov como um mecanismo coerente com essa codificação matricial, o que reforça a compatibilidade destas técnicas com representações grelha-a-grelha.

Em contraste, quando se recorrem a modelos sequenciais como Redes Neurais Recorrentes (RNN) ou Long Short-Term Memory (LSTM), é frequente adotar-se uma estratégia de linearização do nível, o mapa 2D é convertido para uma sequência de símbolos, onde cada

tile/entidade é mapeado para um token (por exemplo, um carácter de um alfabeto discreto), permitindo tratar a geração como um problema análogo a modelação de linguagem. Um exemplo explícito descreve precisamente esta transformação e, para mitigar redundâncias típicas de leitura linha-a-linha (ex., grandes áreas vazias), reorganiza a codificação do nível para uma leitura coluna-a-coluna (uma forma prática de “slicing”), antes de treinar o modelo para prever o próximo símbolo/tile (Zhu et al., 2023). Esta opção está alinhada com a síntese de PCGML, onde níveis de videojogos de plataforma são frequentemente tratados como sequências devido à sua progressão natural, e onde a conversão por slices é apresentada como um expediente representacional que viabiliza a aplicação de modelos 1D (incluindo n-grams e LSTM) a conteúdo originalmente 2D (Zhao & Fan, 2024).

Nos trabalhos que aplicam Transformers, observa-se uma tendência para manter a estrutura do nível como matriz 2D e, em seguida, mapear cada célula (tile/objeto) para uma representação vetorial através de um passo de embedding. Nesta formulação, o nível é descrito como uma grelha onde cada posição contém uma entidade do jogo e, após o embedding, a arquitetura baseada em self-attention passa a operar sobre essa representação em espaço de maior dimensão, beneficiando da capacidade do Transformer para capturar dependências de longo alcance (relevantes para coerência global do layout do nível a ser gerado) (Zhao & Fan, 2024).

Por fim, uma parte relevante da literatura em PCGML discute modelos que operam naturalmente sobre grelhas/imagens, como redes convolucionais, autoencoders e GANs, em que a representação matricial do nível funciona como “imagem” (com codificações por canal/one-hot, dependendo do desenho experimental) (Risi & Togelius, 2020; Wu, 2022). Estas abordagens são frequentemente destacadas pelo seu potencial para capturar padrões espaciais e “estilo” de níveis, e aparecem também associadas a estratégias de avaliação/filtragem com agentes em alguns enquadramentos. Em revisões mais abrangentes sobre PCG com aprendizagem automática e generalização, são também descritas abordagens híbridas em que o modelo generativo aprende uma representação latente do conteúdo e, posteriormente, a geração é guiada por métodos de pesquisa ou otimização nesse espaço latente. Esta estratégia permite introduzir controlo explícito sobre propriedades do nível e explorar diversidade sem depender apenas de amostragem aleatória (Risi & Togelius, 2020).

2.3.4 RQ2 — Mecanismos de adaptação ao jogador e métricas usadas

A adaptação ao jogador, no contexto da geração procedural de níveis 2D, é frequentemente formulada como um problema de controlo por realimentação: observa-se o jogador (ou um proxy do seu comportamento), estima-se um estado/objetivo (por exemplo, se o desafio se mantém adequado) e ajusta-se o conteúdo (parâmetros do nível, seleção de desafios, distribuição de inimigos/itens) para aproximar o jogo desse objetivo. No conjunto de estudos incluídos, as propostas diferenciam-se sobretudo pelo tipo de sinal observado (métricas de desempenho/comportamento e, nalguns casos, medidas subjetivas) e pelo mecanismo de decisão usado para condicionar a seleção/geração do conteúdo (Zook & Riedl, 2015).

Uma linha recorrente é a experience-driven PCG, onde a adaptação assenta num modelo de experiência que liga características do conteúdo e traços do jogador a variáveis como diversão, desafio e frustração. Neste enquadramento, a evidência inclui tanto medições subjetivas recolhidas junto de participantes como métricas comportamentais extraídas da interação (por exemplo, frequência de saltos, corrida e disparos), que são usadas para treinar modelos preditivos e, posteriormente, orientar a procura de conteúdos que maximizem a experiência prevista para um determinado perfil (Yannakakis & Togelius, 2011).

Quando o objetivo é incorporar evolução temporal do desempenho, a adaptação é apresentada como um processo antecipatório: modela-se a progressão do jogador e seleciona-se conteúdo que siga uma trajetória desejada ao longo do tempo. No GAMETAILOR (um sistema de adaptação de desafios temporais, ou seja, um sistema de ajuste de desafios ao longo do tempo), esta ideia é operacionalizada através de tensor factorization para prever desempenho e de constrained optimization para escolher desafios que aproximem o desempenho previsto de uma performance curve definida pelo designer, permitindo ajustar o desafio de forma consistente com a progressão pretendida (Zook & Riedl, 2015).

Há também evidência de adaptação formulada como balanceamento dinâmico suportado por uma métrica de erro diretamente observável. No mecanismo inspirado em ecossistemas, o objetivo pode ser expresso por uma condição mensurável (por exemplo, terminar uma ronda com a vida do jogador próximo de zero), convertendo o desvio ao objetivo num erro percentual face a vida máximo e reduzindo esse erro ao longo de gerações através de Particle Swarm Optimization (PSO) numa estrutura multinível. Os resultados reportam estabilização do erro, na maioria dos testes, num intervalo próximo de $[-5\%, 5\%]$, sendo a convergência influenciada por alterações na força do jogador (armadura e vida máxima) (Xia & Anand, 2016).

Algumas abordagens aproximam a adaptação de critérios automáticos de solubilidade e “adequação” do desafio, recorrendo a agentes como mecanismo de verificação. No trabalho de (Rajabi et al., 2021) níveis gerados por Deep Convolutional Generative Adversarial Network (DCGAN) são filtrados por requisitos mínimos estruturais e por um critério de solubilidade com limiares explícitos: níveis resolvidos demasiado rapidamente são tratados como fáceis e níveis que exigem demasiadas tentativas como difíceis, sendo a condição de aceitabilidade expressa por um intervalo de tentativas (por exemplo, entre 10 e 300 episódios) verificado por um agente.

Por fim, embora não esteja restrito a geração de níveis 2D, o Balanced Difficulty Task Finder (método de adaptação da dificuldade, cujo objetivo é escolher, a cada passo, uma tarefa com dificuldade ajustada ao nível do utilizador para manter um equilíbrio entre competência e desafio), fornece uma formalização útil do objetivo de adaptação alinhada com a noção de “desafio adequado”: a dificuldade é definida numa escala contínua $[0,1]$, assume-se uma relação monotonia com a probabilidade de sucesso e ajusta-se a dificuldade online para convergir para uma probabilidade-alvo s (por exemplo, $s=0,7$), através de uma regra de atualização dependente de sucesso/fracasso e parâmetros que controlam a rapidez de convergência (Yazidi et al., 2020).

2.3.5 RQ3 — Métodos de validação algorítmica da jogabilidade

Nos estudos analisados, a validação da jogabilidade em níveis 2D gerados automaticamente surge sobretudo como um problema de verificação de propriedades mínimas (ex. se existir um percurso viável entre início e fim), e em alguns casos, como quantificação do esforço/dificuldade. Em termos práticos, isto traduz-se na combinação de (i) testes estruturais sobre a representação do nível (grelha/tiles), (ii) métodos de procura/planeamento para confirmar alcançabilidade, e (iii) mecanismos de filtragem/seleção e/ou reparação quando se detetam falhas (Summerville et al., 2018).

Uma linha recorrente é a validação por procura baseada em agentes (playability/solvability checks), onde o nível só é aceite se um agente conseguir completar o objetivo sob regras definidas. Em geração generalista baseada em cadeias de Markov, a jogabilidade é avaliada através da execução de agentes/controladores que tentam jogar o nível, permitindo filtrar automaticamente níveis inviáveis antes de serem disponibilizados (Zafar et al., 2019)

Outra estratégia, típica em abordagens com modelos generativos profundos, é impor requisitos mínimos e depois aplicar um critério explícito de solvabilidade por simulação. No estudo que usa DCGAN para níveis 2D, os níveis gerados são primeiro filtrados por condições como ter exatamente um início e um fim, limites para moedas e um número mínimo de plataformas. Adicionalmente, a solvabilidade é verificada com uma pesquisa assistida por Reinforcement Learning (RL), impondo-se que o nível seja resolúvel num intervalo de tentativas (por exemplo, entre 10 e 300 episódios) para evitar níveis “demasiado fáceis” ou “demasiado difíceis (Rajabi et al., 2021)”.

Quando a preocupação é a robustez do gerador (especialmente em geração offline), a validação aparece sob a forma de identificação e mitigação de falhas catastróficas que tornam o nível impraticável (ex: geometria que prende o jogador, gaps acima da capacidade de salto, conteúdo opcional fora de alcance, ou até degradação do nível para casos triviais quando há pouca informação). O trabalho sobre Mario descreve estas falhas como problemas que podem tornar níveis “impossível de jogar” ou “muito simples” e propõe uma verificação por restrições/heurísticas para filtrar níveis com esse tipo de anomalias (Volz et al., 2018).

Em paralelo, há abordagens mais “engenharia de jogo” que operacionalizam validação como capacidade de navegação consistente com a física da plataforma. O framework de pathfinding para jogos 2D plataforma formaliza o nível como um grafo de plataformas e liga pontos de salto/aterragem com trajetórias calculadas por equações cinemáticas. A navegação combina algoritmos baseados em A* para deslocação no solo com um algoritmo específico para movimentos verticais/saltos, permitindo testar automaticamente se há caminho entre posições e apoiar comportamentos de Non-Player Characters (NPC's) (Wicaksana et al., 2025).

A literatura recente também evidencia que a validação algorítmica da jogabilidade não se limita a verificar “se o nível é possível”, mas pode ser operacionalizada como validação operacional e avaliação indireta do gerador através de playtesting simulado e modelos substitutos. Na síntese

de (Liu et al., 2021), é destacado que agentes (incluindo deep reinforcement learning) podem produzir playtraces (a sequência de ações e estados do jogo ao longo do tempo) e sinais de desempenho que ajudam a caracterizar rapidamente o espaço gerativo e a identificar enviesamentos ou regiões problemáticas, permitindo validar operacionalmente a jogabilidade e, por extensão, avaliar o próprio gerador quando esses resultados são usados para estratificar o espaço de geração.

Complementarmente, a validação pode assumir a forma de análise sistemática das propriedades do conteúdo gerado, em vez de depender apenas de verificações pontuais. Segundo o estudo (Schaa & Barriga, 2024) pode-se aplicar a técnica Expressive Range Analysis (ERA) para avaliar geradores de níveis de Super Mario Bros, comparando outputs de diferentes abordagens (incluindo geradores open-source) e discutindo a utilidade de métricas/descriptores para evidenciar cobertura do espaço de níveis e padrões de qualidade, reforçando a ERA como ferramenta de auditoria do comportamento do gerador e de detecção de falhas recorrentes.

Em contextos search-based PCG, a validação é frequentemente materializada numa função objetivo (fitness) que agrega critérios de jogabilidade/qualidade. Neste cenário, a dificuldade passa a ser também “o quão bem essa função guia a procura”. Ao utilizar ferramentas de Exploratory Landscape Analysis para caracterizar propriedades do fitness landscape (ex: indícios de rugosidade, estrutura e semelhança entre problemas) e com isso, apoiar escolhas metodológicas mais informadas, como selecionar algoritmos de procura mais adequados e interpretar porque certas formulações de validação conduzem a convergência fraca ou soluções pouco úteis (Volz et al., 2023).

Por fim, quando a validação falha, alguns trabalhos avançam para reparação automática: detetam onde a alcançabilidade é quebrada e alteram o nível para restaurar a jogabilidade. No método de “reachability repair” para plataformas side-scrolling, o processo descrito passa por corrigir erros lógicos, usar um “level-break agent” para localizar os tiles que tornam o nível inalcançável e, por fim, substituir tiles com um modelo de deep learning para tornar o nível alcançável, demonstrando o procedimento em níveis de Super Mario Bros (Fukuda et al., 2020).

2.3.6 RQ4 — Telemetria do jogador, privacidade e conformidade legal

Na literatura encontramos exemplos geração/adaptação de níveis, onde a telemetria é predominantemente comportamental e “leve”: recolhem-se métricas de estilo e desempenho durante o jogo e complementa-se, quando necessário, com avaliação subjetiva. No caso descrito para níveis ao estilo Super Mario, os participantes classificam estados afetivos (como diversão, desafio, frustração, previsibilidade, ansiedade, tédio) e o sistema regista indicadores de estilo (frequência de saltos, corrida e disparos), além de outras variáveis de jogo; estes dados são usados para treinar modelos preditivos e, depois, otimizar níveis para perfis específicos (Yannakakis & Togelius, 2011).

Em paralelo, a telemetria pode ser enriquecida com sinais “objetivos” (para além do log de ações), sobretudo quando o objetivo é inferir estados afetivos/cognitivos. Estas abordagens híbridas que combinam autorrelato com medidas de psicofisiologia e com dados anotados de vídeo e/ou fala, para ligar estados afetivos a características de jogabilidade. Embora isto aumente a capacidade de modelação, eleva também o risco de intrusão, por envolver dados potencialmente mais identificáveis e sensíveis (Yannakakis & Togelius, 2011).

Quando o foco é adaptação ao longo do tempo, a telemetria é tratada como série temporal de desempenho: em vez de reagir só ao “momento”, o sistema procura prever evolução (aprendizagem/fadiga) e selecionar conteúdo para seguir uma trajetória-alvo definida pelo designer. Esta ideia é operacionalizada com modelação/predição temporal e seleção de conteúdo sob restrições, alinhada com uma performance curve desejada (Zook & Riedl, 2015).

Há ainda evidência clara (embora fora de PCG de níveis 2D “puro”) de como sistemas interativos instrumentados exploram telemetria granular para prever abandono/engajamento: podemos observar registos de logs detalhados (tempo total, cliques em botões, uso de ajuda, tempo em componentes da interface, edições de código, conclusão de níveis) e, quando há conta, recolhe também atributos como e-mail, idade e género. Este tipo de instrumentação é um bom paralelo para argumentar que “telemetria” pode rapidamente deixar de ser apenas desempenho e passar a incluir identificadores (Yan et al., 2017). Em RGPD, isto liga-se diretamente a princípios como limitação da finalidade e minimização dos dados (recolher apenas o necessário para o objetivo declarado), bem como integridade/confidencialidade e limitação da conservação. Em sistemas adaptativos, uma leitura prática destes princípios é: preferir métricas agregadas e não identificáveis (ex.: contagens, tempos, taxas), evitar recolher identificadores diretos quando não são essenciais, e separar qualquer identificador (conta/e-mail) da telemetria operacional, idealmente com pseudonimização. Finalmente, quando a adaptação usa modalidades como voz/vídeo (ex.: para inferir frustração/emoções), o risco de re-identificação e o potencial enquadramento como dados mais sensíveis aumentam, exigindo maior cautela: por defeito, recolher menos, processar localmente sempre que possível, definir retenção curta e aplicar privacy by design/by default desde o desenho do sistema (o “mínimo por defeito”).

2.4 Discussão

Discussion

2.4.1 RQ1 — Modelos generativos e representações de níveis 2D

Os estudos analisados sugerem que, em geração procedural de níveis 2D, a principal decisão de desenho não é apenas sobre qual o modelo a usar também, mas de que forma terá o nível para o modelo aprender. A literatura em PCG com aprendizagem automática organiza este problema distinguindo a estrutura subjacente dos dados (sequência, grelha ou grafo) dos métodos de aprendizagem/geração (ex. contagem de frequências, redes neuronais, factorização),

mostrando que escolhas semelhantes reaparecem em formatos distintos e com objetivos diferentes (Summerville et al., 2018).

Nas abordagens probabilísticas clássicas (cadeias de Markov/n-gramas), observa-se uma preferência por capturar regularidades locais, ou através da linearização do nível em fatias recorrentes (quando a progressão é predominantemente lateral), ou através de vizinhanças 2D quando o nível é tratado diretamente como grelha (Summerville et al., 2018; Zafar et al., 2019). A formulação 2D é particularmente explícita em contextos mais gerais (VGDL/GVG-LG), onde o nível é uma matriz 2D de sprites e o modelo estima transições condicionadas por dependências espaciais (ex. esquerda/topo), reforçando a adequação destas técnicas quando o objetivo é coerência local e simplicidade do gerador (Zafar et al., 2019).

Nos modelos sequenciais baseados em LSTM, o corpus tende a explorar a analogia com modelação de linguagem, o nível é convertido numa sequência de símbolos, mas essa escolha introduz um compromisso claro entre facilidade de treino e preservação de estrutura espacial. Um exemplo concreto mostra que ler o nível linha-a-linha pode amplificar redundâncias (ex. “céu” repetido) e dificultar a aprendizagem de padrões relevantes, por isso adota-se leitura coluna-a-coluna (rotação 90°) para tornar o padrão estrutural mais evidente. Ainda assim, a limitação de comprimir sequências longas num estado oculto fixo é apontada como causa de desordem simbólica. A introdução de mecanismos de atenção surge precisamente para dar peso diferenciado a partes relevantes da sequência e melhorar consistência/coerência do nível gerado (Summerville et al., 2018).

O recurso a arquiteturas Transformer é interpretável como resposta direta a este problema: em vez de depender apenas de memória recorrente, a self-attention permite modelar dependências de longo alcance (relevantes para coerência global do layout). Na prática, os trabalhos descrevem uma pipeline recorrente: nível como matriz de tiles, mapeamento tile-para-vetor (embedding) e adição de codificação posicional para reintroduzir no modelo noção de localização espacial. Isto mantém a grelha como objeto central, mas aumenta a capacidade do modelo para relacionar regiões distantes do nível durante a geração (Zhao & Fan, 2024).

Em paralelo, modelos “tipo imagem” (convolucionais, autoencoders e GAN) beneficiam da grelha por captarem bem padrões espaciais e “estilo”, mas a discussão sobre conteúdo funcional reforça que um nível possa “parecer certo”, mas isso não é garantia que seja um nível “funcionar”: restrições de jogabilidade dependem frequentemente de relações não locais (ex. conectividade, contagens, saltos possíveis), o que pode levar a artefactos visualmente plausíveis, mas inviáveis. Por esse motivo, é frequente defender-se a combinação de modelos aprendidos com mecanismos de verificação/seleção e, sobretudo, a exploração de geração guiada por objetivos através de procura no espaço latente (em vez de amostragem cega), para introduzir controlo explícito sobre propriedades do nível (Summerville et al., 2018; Zafar et al., 2019).

Por fim, tal como perguntas de investigação seguintes, emerge uma limitação transversal: a comparação entre abordagens é dificultada por configurações heterogéneas (jogos,

representações, métricas e datasets), e a escassez de dados reutilizáveis permanece um entrave prático (muitos estudos treinam dentro de um jogo/série), apesar de iniciativas de corpus/formatos comuns. Isto sugere que parte da análise realizada nesta literatura relacionada com a pergunta de investigação 1 evolui, não só por melhorias arquiteturais, mas também por decisões de normalização representacional e pela disponibilização de dados/benchmarks que suportem generalização e avaliação consistente.

Em síntese, o padrão dominante combina grelhas de tiles com modelos que maximizam coerência espacial (do probabilístico local ao deep learning com atenção), enquanto representações sequenciais continuam úteis quando a progressão do nível impõe uma ordenação natural, contudo a robustez funcional e a comparabilidade entre estudos continuam dependentes de escolhas de representação, disponibilidade de dados e validação estruturada do conteúdo gerado.

2.4.2 RQ2 — RQ2: Mecanismos de adaptação ao jogador e métricas usadas

Os estudos analisados sugerem que a adaptação ao jogador em PCG de níveis 2D é, na prática, um ciclo de controlo: observa-se o jogador (ou um proxy), estima-se um estado desejado (ex. se o desafio é adequado) e ajusta-se o conteúdo para reduzir o desvio face a esse objetivo. As diferenças entre propostas não estão apenas “no gerador”, mas sobretudo em (i) que sinal é observado e (ii) como esse sinal é convertido numa decisão sobre geração/seleção de conteúdo (Zook & Riedl, 2015).

Um técnica recorrente é a experience-driven PCG, onde a adaptação depende de um modelo que liga traços do jogador e características do conteúdo a variáveis de experiência (diversão, frustração, desafio). A vantagem é o alinhamento com objetivos centrados no utilizador; o custo é a dependência de medidas de referência baseadas em auto-relato e de recolha/rotulagem (questionários, escalas), processos geralmente dispendiosos e sensíveis ao contexto. Em muitos casos, por pragmatismo, estas variáveis acabam por ser aproximadas por telemetria comportamental (ex. ações frequentes, padrões de movimento), o que melhora escalabilidade, mas aumenta o risco de o sistema otimizar proxies que nem sempre correspondem à experiência real (Yannakakis & Togelius, 2011).

Outra abordagem assume a adaptação como controlo antecipatório: em vez de reagir apenas ao estado atual, modela-se a progressão do jogador e escolhe-se conteúdo para seguir uma trajetória definida pelo designer. O GAMETAILOR é um exemplo claro desta lógica, ao usar previsão (tensor factorization) e seleção sob restrições (constrained optimization) para aproximar o desempenho previsto de uma performance curve desejada (Zook & Riedl, 2015). A leitura crítica aqui é que esta abordagem torna explícita a intenção do designer (curva-alvo), mas exige modelos preditivos estáveis e um desenho cuidadoso da curva, sob pena de induzir “correções” artificiais ou instáveis em jogadores com estilos não previstos.

Outra família formula a adaptação como minimização direta de erro com otimização online. O mecanismo inspirado em ecossistemas traduz o objetivo (p. ex., terminar com vida perto de

zero) num erro mensurável e usa PSO para reduzir esse erro ao longo de gerações, reportando convergência para um intervalo pequeno na maioria dos testes (Xia & Anand, 2016). Este tipo de abordagem é apelativo pela clareza do objetivo e por funcionar com feedback simples; contudo, tende a ser altamente dependente de como se define o erro e do quão bem esse erro representa “dificuldade justa” (por exemplo, vida perto de zero pode corresponder a tensão positiva ou a frustração, dependendo do jogador).

Observa-se também adaptação operacionalizada como verificação/filtragem por agentes, aproximando “adequação” de critérios automáticos de solubilidade e dificuldade observável. No caso de níveis DCGAN filtrados por um agente, a dificuldade é inferida por limiares de episódios/tentativas: níveis resolvidos demasiado depressa são tratados como fáceis e níveis que exigem demasiadas tentativas como difíceis (Rajabi et al., 2021). Esta estratégia é útil quando se pretende garantir um mínimo de funcionalidade sem depender de estudos com humanos, mas desloca o problema para a fidelidade do agente: se o agente não representa bem o comportamento humano, a adaptação pode tornar-se enviesada (níveis “bons para o agente” não são necessariamente “bons para pessoas”).

Por fim, propostas mais gerais como o Balanced Difficulty Task Finder oferecem uma formalização elegante do alvo de adaptação: convergir para uma probabilidade de sucesso s (p. ex., 0,7) através de atualização online baseada em sucesso/fracasso (Yazidi et al., 2020). A utilidade desta formalização, no contexto 2D, é servir como “regra de bolso” robusta: define-se um alvo simples, observável e interpretável. A limitação é que, tal como nas restantes abordagens, a noção de dificuldade pode ficar “achatada” se for reduzida a sucesso/fracasso, ignorando aspetos como estilo de jogo, exploração, risco ou preferências.

No conjunto, emerge um compromisso transversal: quanto mais rica é a noção de adaptação (experiência subjetiva, progressão, preferências), maior o custo de dados e validação; quanto mais simples e operacional é o sinal (erro, sucesso, episódios), mais fácil é implementar e avaliar, mas maior o risco de otimizar um proxy incompleto. Assim, a tendência prática aponta para soluções híbridas: telemetria comportamental como sinal principal, objetivos explícitos (alvo de sucesso/curva) como guardrails, e mecanismos de verificação (agentes/constraints) para evitar casos patológicos, articulando naturalmente com as preocupações de validação discutidas na RQ3 (Zook & Riedl, 2015; Yannakakis & Togelius, 2011; Rajabi et al., 2021).

Em síntese, a literatura em RQ2 sugere que a adaptação em PCG de níveis 2D é menos uma “técnica única” e mais uma arquitetura de decisão: escolher sinais observáveis, definir um alvo interpretável e aplicar um mecanismo de controlo (otimização, filtragem, seleção guiada) que seja compatível com as restrições do jogo e com o grau de personalização pretendido (Zook & Riedl, 2015; Yazidi et al., 2020).

2.4.3 RQ3 —

Iniciar um capítulo novo sempre numa página à direita (ímpar).

2.4.4 RQ4 —

Iniciar um capítulo novo sempre numa página à direita (ímpar).

2.5 Conclusions and future work

Iniciar um capítulo novo sempre numa página à direita (ímpar).

**Inserir página em branco apenas se necessário de modo
que o próximo capítulo comece numa página à direita**

3 State of the Art and Systematic Review of the Literature

3.1 Introduction

Proteção de Dados em Sistemas de Geração Procedural Adaptativa: Um State of Knowledge sobre Anonimização de Telemetria de Jogadores

O State of Knowledge (SoKw) será centrado na análise de técnicas de anonimização e pseudonimização aplicadas a dados de telemetria em videojogos e por extensão, em sistemas inteligentes interativos. Este estudo irá identificar e classificar trabalhos que utilizem registos de jogo, métricas de desempenho ou dados fisiológicos de jogadores para fins de adaptação, personalização ou análise e com isso identificar os principais riscos de privacidade associados a estes dados (por exemplo, reidentificação, perfis comportamentais de longo prazo, inferência de estados emocionais), bem como as abordagens privacy-by-design propostas, incluindo estratégias de minimização de dados, agregação, pseudonimização e controlo local da informação e como enquadra-se o Regulamento Geral sobre a Proteção de Dados (RGPD).

**Inserir página em branco apenas se necessário de modo
que o próximo capítulo comece numa página à direita**

Referências

- British Academy of Film, & Arts, T. (2025). *BAFTA Games Awards 2025*.
<https://www.bafta.org/awards/games/>
- Electronic Arts Inc. (2020). *Dynamic difficulty adjustment based on player retention and performance* (Issue US20200206631A1).
<https://patents.google.com/patent/US20200206631A1>
- European Commission. (2023). *Case M.10646 – Microsoft / Activision Blizzard*.
https://ec.europa.eu/competition/mergers/cases/decisions/m10646_9311516_7443_3.pdf
- Fukuda, T., Katai, O., & Ueda, S. (2020). Side-Scrolling Platform Game Levels Reachability Repair Method and Its Applications to Super Mario Bros. *IEICE Transactions on Information and Systems*, E103.D(9), 2058–2071.
<https://doi.org/10.1587/transinf.2019EDP7245>
- International Trade Administration. (2023). *Media and Entertainment: Video Games Sector*.
- Liu, J., Khalifa, A., & Togelius, J. (2021). Deep learning for procedural content generation. *Neural Computing and Applications*, 33, 1525–1543.
<https://doi.org/10.1007/s00521-020-05383-8>
- Rajabi, M., Ashtiani, M., Minaei-Bidgoli, B., & Davoodi, O. (2021). A dynamic balanced level generator for video games based on deep convolutional generative adversarial networks. *Scientia Iranica*, 28(3), 1497–1514.
<https://doi.org/10.24200/sci.2020.54747.3897>
- Risi, S., & Togelius, J. (2020). *Increasing Generality in Machine Learning through Procedural Content Generation*.
- Schaa, H., & Barriga, N. A. (2024). Evaluating the Expressive Range of Super Mario Bros Level Generators. *Algorithms*, 17(7), 307. <https://doi.org/10.3390/a17070307>
- Sony Computer Entertainment Inc. (2011). *Adaptive game difficulty using biometric feedback* (Issue US20110260830A1).
<https://patents.google.com/patent/US20110260830A1>
- Sony Interactive Entertainment. (2022). *PS5 price to increase in select markets due to global economic environment including high inflation rates*.
<https://blog.playstation.com/2022/08/25/ps5-price-to-increase-in-select-markets-due-to-global-economic-environment-including-high-inflation-rates/>

- Sony Interactive Entertainment. (2024). *PS5 Pro Technical Seminar reveals new in-depth details on console*. <https://blog.playstation.com/2024/12/18/ps5-pro-technical-seminar-reveals-new-in-depth-details-on-console/>
- Sony Interactive Entertainment. (2025). *PS5 price to rise in Europe, Australia, and New Zealand*. <https://blog.playstation.com/2025/04/13/ps5-price-to-rise-in-europe-australia-and-new-zealand/>
- Summerville, A., Snodgrass, S., Guzdial, M., Holmgaard, C., Hoover, A. K., Isaksen, A., Nealen, A., & Togelius, J. (2018). Procedural Content Generation via Machine Learning (PCGML). *IEEE Transactions on Games*, 10(3), 257–270. <https://doi.org/10.1109/TG.2018.2846639>
- The Game Awards. (2018). *The Game Awards 2018 – Awards and Winners*. <https://thegameawards.com/rewind/year-2018>
- Volz, V., Naujoks, B., Kerschke, P., & Tušar, T. (2023). Tools for Landscape Analysis of Optimisation Problems in Procedural Content Generation for Games. *Applied Soft Computing*, 136, 110121. <https://doi.org/10.1016/j.asoc.2023.110121>
- Volz, V., Snodgrass, S., Steine-Hanson, Z., Liang, J., Smith, A. M., & others. (2018). Identifying Catastrophic Failures in Offline Level Generation for Mario. *Proceedings of the 13th International Conference on the Foundations of Digital Games (FDG '18)*. <https://doi.org/10.1145/3235765.3235826>
- Wicaksana, B. A., Herumurti, D., & Kuswardayan, I. (2025, September). Enhancing Game Development Efficiency: A Reusable AI Pathfinding Framework for 2D Platformer Games. *2025 12th International Conference on Electrical Engineering, Computer Science and Informatics (EECSI)*. <https://doi.org/10.1109/EECSI67060.2025.11290481>
- Wu, A. N. (2022). Generative Adversarial Networks in the built environment: A review of the application of GANs across data types and scales. *Building and Environment*, 223, 109477. <https://doi.org/10.1016/j.buildenv.2022.109477>
- Xia, W., & Anand, B. (2016). Game balancing with ecosystem mechanism. *2016 International Conference on Data Mining and Advanced Computing (SAPIENCE)*. <https://doi.org/10.1109/SAPIENCE.2016.7684145>
- Yan, A., Lee, M. J., & Ko, A. J. (2017). Predicting Abandonment in Online Coding Tutorials. *2017 IEEE Symposium on Visual Languages and Human-Centric Computing (VL/HCC)*, 191–199. <https://doi.org/10.1109/VLHCC.2017.8103467>
- Yannakakis, G. N., & Togelius, J. (2011). Experience-Driven Procedural Content Generation. *IEEE Transactions on Affective Computing*, 2(3), 147–161. <https://doi.org/10.1109/T-AFFC.2011.6>

- Yazidi, A., Abolpour Mofrad, A., Goodwin, M., Hammer, H. L., & Arntzen, E. (2020). Balanced difficulty task finder: an adaptive recommendation method for learning tasks based on the concept of state of flow. *Cognitive Neurodynamics*.
<https://doi.org/10.1007/s11571-020-09624-3>
- Zafar, A., Irfan, A., & Sabir, M. Z. (2019). *Generating General Levels using Markov Chains*.
- Zhao, T., & Fan, Z. (2024). Enhancing Procedural Game Level Generation using Transformer-based Neural Architectures. *2024 International Symposium on Internet of Things and Smart Cities (ISITSC)*.
<https://doi.org/10.1109/ISITSC64373.2024.00007>
- Zhu, J., Gao, T., & Mi, Q. (2023). Automatic Creation of LSTM Game Level Based on Attention Mechanism. *2023 6th International Seminar on Research of Information Technology and Intelligent Systems (ISRITI)*.
<https://doi.org/10.1109/ISRITI60336.2023.10467911>
- Zook, A., & Riedl, M. O. (2015). Temporal Game Challenge Tailoring. *IEEE Transactions on Computational Intelligence and AI in Games*, 7(4), 336–346.
<https://doi.org/10.1109/TCIAIG.2014.2342934>

Exemplos, não apagar para já

...

(EurAI 2022)

European Association for Artificial Intelligence,
 EurAI, viewed 7 January 2022,
<https://eurai.org/>

...

(Ortony 1993)

Ortony AE. (1993). Metaphor and thought. Cambridge University Press.

...

(Ramos et al. 2008)

Ramos, C., Augusto, J. C., & Shapiro, D. (2008). Ambient intelligence—the next step for artificial intelligence. *IEEE Intelligent Systems*, 23(2), 15-18.

...

ou alternativamente

...

[14] Marreiros G, Santos R, Ramos C, Neves J. Context-aware emotion-based model for group decision making. *IEEE Intelligent Systems*. 2010; 25(2), p. 31-39.

...

[22] Faria L, Silva A, Vale Z, Marques A. Training control centers' operators in incident diagnosis and power restoration using intelligent tutoring systems. *IEEE Transactions on Learning Technologies*. 2009; 2(2), p. 135-147.

...

[31] Vale Z, Gomes L, Faria P, Ramos C. Intelligent Energy-Oriented Home. In: Kaur G, Tomar P, Tanque M, editors. *Artificial Intelligence to Solve Pervasive Internet of Things Issues*. . Academic Press. 2020; p. 269-289.